

# Projet 2 : Analyse des données de systèmes éducatifs.

Ilham NOUMIR



academy

## **Contexte:**

**une start-up de la EdTech,  
nommée academy;**

## **Expansion à l'international**

- 

### **Mission:**

- Quels sont les pays avec un fort potentiel de clients pour nos services ?
- Pour chacun de ces pays, quelle sera l'évolution de ce potentiel de clients ?
- Dans quels pays l'entreprise doit-elle opérer en priorité ?

## Objectifs de l'étude:

- Valider la qualité de ce jeu de données (comporte-t-il beaucoup de données manquantes, dupliquées ?)
- Décrire les informations contenues dans le jeu de données (nombre de colonnes ? nombre de lignes ?)
- Sélectionner les informations qui semblent pertinentes pour répondre à la problématique (quelles sont les colonnes contenant des informations qui peuvent être utiles pour répondre à la problématique de l'entreprise ?)
- Déterminer des ordres de grandeurs des indicateurs statistiques classiques pour les différentes zones géographiques et pays du monde (moyenne/médiane/écart-type par pays et par continent ou bloc géographique

# Plan du travail:

1. Vérification de la qualité des données :

- Description globale des données;
- Données manquantes et données dupliquées sur l'ensemble de la dataframe;
- Données manquantes sur les colonnes des dataframes;
- Elimination Des colonnes non remplies;
- Analyse Statistique globale des Dataframes avec la fonction describe()

2. Première visualisation des données: (Compréhension de l'objet des dataframes)

- Nombre de pays par région;
- Répartition des pays par unité monétaire;
- Nombre d'indicateurs par sujet (Topic);
- Nuage des mots;

3. Filtrage et regroupement des données :

- Filtrage de l'intervalle de l'étude : Quels sont les années qu'on peut utiliser pour notre étude;
- Filtrage des pays d'étude;
- Filtrage en fonction des indicateurs;
- Sélection minimale des indicateurs à analyser

4. Visualisation des indicateurs choisis:

5. Analyse bivariée

6. Classement des pays par potentiel d'implémentation via un scoring

7. Evaluation du potentiel des pays choisis;

# Méthodologie du travail:

**1.  
Compréhension  
des données.**

**2.  
Visualisation**

**3.  
Filtrage des  
données**

**4.  
Choix des indicateurs**

**5.  
Scoring des pays**

# 1. Compréhension et vérification de la qualité des données

**5 jeu de données :**

```
-----  
country  
La dimension de la dataframe country : (241, 32)  
-----  
indicateurs  
La dimension de la dataframe indicateurs : (3665, 21)  
-----  
data  
La dimension de la dataframe data : (886930, 70)  
-----  
source  
La dimension de la dataframe source : (613, 4)  
-----  
description  
La dimension de la dataframe description : (643638, 5)
```

**Durée de 1970 à 2050**

**241 pays**

**3665 Indicateurs**

# 1. Compréhension et vérification de la qualité des données


## Valeurs manquantes et valeurs dupliquées

```
-----  
country  
Le pourcentage des NAN dans la totalité de la Dataframe country : 30.52  
La somme des valeurs dupliquées dans la Dataframe country : 0  
-----  
indicateurs  
Le pourcentage des NAN dans la totalité de la Dataframe indicateurs : 71.72  
La somme des valeurs dupliquées dans la Dataframe indicateurs : 0  
-----  
data  
Le pourcentage des NAN dans la totalité de la Dataframe data : 86.1  
La somme des valeurs dupliquées dans la Dataframe data : 0  
-----  
source  
Le pourcentage des NAN dans la totalité de la Dataframe source : 25.0  
La somme des valeurs dupliquées dans la Dataframe source : 0  
-----  
description  
Le pourcentage des NAN dans la totalité de la Dataframe description : 20.0  
La somme des valeurs dupliquées dans la Dataframe description : 0
```

# 1. Compréhension et vérification de la qualité des données

Les valeurs manquantes pour chaque colonne de la Dataframe: Country


| % of Total Values                                 |            |
|---|------------|
| Unnamed: 31                                       | 100.000000 |
| National accounts reference year                  | 86.721992  |
| Alternative conversion factor                     | 80.497925  |
| Other groups                                      | 75.933610  |
| Latest industrial data                            | 55.601660  |
| Vital registration complete                       | 53.941909  |
| External debt Reporting status                    | 48.547718  |
| Latest household survey                           | 41.493776  |
| Latest agricultural census                        | 41.078838  |
| Lending category                                  | 40.248963  |
| PPP survey year                                   | 39.834025  |
| Special Notes                                     | 39.834025  |
| Source of most recent Income and expenditure data | 33.609959  |
| Government Accounting concept                     | 33.195021  |
| Latest water withdrawal data                      | 25.726141  |
| Balance of Payments Manual in use                 | 24.896266  |
| IMF data dissemination standard                   | 24.896266  |
| Latest trade data                                 | 23.236515  |
| SNA price valuation                               | 18.257261  |



# 1. Compréhension et vérification de la qualité des données

Les valeurs manquantes pour chaque colonne de la Dataframe: Indicateurs


|                                     | % of Total Values |
|-------------------------------------|-------------------|
| Unnamed: 20                         | 100.000000        |
| Related indicators                  | 100.000000        |
| Other web links                     | 100.000000        |
| Unit of measure                     | 100.000000        |
| License Type                        | 100.000000        |
| Notes from original source          | 100.000000        |
| Development relevance               | 99.918145         |
| General comments                    | 99.618008         |
| Limitations and exceptions          | 99.618008         |
| Statistical concept and methodology | 99.372442         |
| Aggregation method                  | 98.717599         |
| Periodicity                         | 97.298772         |
| Related source links                | 94.133697         |
| Base Period                         | 91.432469         |
| Other notes                         | 84.938608         |
| Short definition                    | 41.173261         |
| Source                              | 0.000000          |
| Long definition                     | 0.000000          |
| Indicator Name                      | 0.000000          |
| Topic                               | 0.000000          |



# 1. Compréhension et vérification de la qualité des données


Les valeurs manquantes pour chaque colonne de la Dataframe: Data

|    | name_of_colone | % of Total Values |
|----|----------------|-------------------|
| 0  | 1993           | 91.454455         |
| 1  | 1996           | 91.340128         |
| 2  | 1994           | 91.266278         |
| 3  | 1998           | 90.426076         |
| 4  | 1975           | 90.156382         |
| 5  | 1980           | 89.951631         |
| 6  | 1985           | 89.819264         |
| 7  | 2014           | 87.170464         |
| 8  | 1999           | 86.601085         |
| 9  | 2001           | 86.074549         |
| 10 | 2002           | 85.996076         |
| 11 | 1990           | 85.973527         |
| 12 | 2004           | 85.476419         |
| 13 | 2003           | 85.301771         |
| 14 | 2015           | 85.223411         |
| 15 | 1995           | 85.189248         |
| 16 | 2008           | 84.848071         |
| 17 | 2007           | 84.522792         |
| 18 | 2013           | 84.496071         |
| 19 | 2006           | 84.180037         |
| 20 | 2009           | 83.977541         |
| 21 | 2011           | 83.537370         |
| 22 | 2012           | 83.396209         |
| 23 | 2000           | 80.080051         |



## 2. Visualisation des données


### Les pays par région



On remarque que la région de l'Europe et le centre d'Asie contient plus de pays en matière de nombre

## 2. Visualisation des données


### Les pays par classe de revenue



Beaucoup de pays ont des revenus moyens supérieurs

## 2. Visualisation des données


### L'unité monétaire des pays



Nombreux sont les pays qui ont l'unité monétaire de l'Euro


## 2. Visualisation des données

NUAGE DES POINTS DES MOTS LES PLUS RÉCURRENTS DANS LES INDICATEURS:




## 2. Visualisation des données

mots clés récurrents dans les indicateurs :




### 3. Filtrage des données

L'intervalle des années qu'on peut utiliser dans notre étude :




### 3. Filtrage des données

Filtrage par pays :




### 3. Filtrage des données

### 3. Filtrage des données / Indicateurs choisis




## 4. Visualisation des indicateurs choisis:

PIB




## 4. Visualisation des indicateurs choisis:

**PIB**




## 4. Visualisation des indicateurs choisis:



## 4. Visualisation des indicateurs choisis:


### Population 15-24



Activer Windo


## 4. Visualisation des indicateurs choisis:

Internet  
Users




## 4. Visualisation des indicateurs choisis:

### Ordinateurs personnels




## 4. Visualisation des indicateurs choisis:

### Population par région



## 4. Visualisation des indicateurs choisis:


### Population 15-24 par région




Active  
Accédez

## 4. Visualisation des indicateurs choisis:

**Utilisateurs  
d'Internet et  
ordinateurs  
personnels  
par région**




## 5. Analyse bivariée des indicateurs choisis :



## 5. Analyse bivariée des indicateurs choisis :

Analyse bivariée des indicateurs choisi



## 6 . Classement des pays par potentiel d'implémentation via un scoring :

### PIB

- 1.Japan
2. Norway
- 3.Switzerland
- 4.United States
- 5.United Arab Emirates
- 6.Denmark
- 7.Sweden
- 8.United Kingdom
- 9.Netherlands
- 10.Hong Kong SAR

### Population

- 1.China
2. India
- 3.United States
- 4Indonesia
5. Brazil
6. pakistan
- 7.Nigeria
- 8.Bangladesh
- 9.Russia Federation
- 10.Japan

### population 15-24

- 1.India
- 2.China
- 3.United States
- 4Indonesia
5. Brazil
6. pakistan
- 7.Nigeria
- 8.Bangladesh
- 9.Russia Federation
- 10.Ethiopia

### Utilisateurs d'Internet

- 1.Norway
2. Denmark
- 3.Sweden
4. Netherlands
- 5.United Kingdom
- 6.Finland
- 7.Japan
- 8.United Arab Emirates
- 9.Canada
- 10.Germany

### Ordinateurs personnel

- 1.Switzerland
- 2.United States
- 3.Sweden
- 4.Denmark
- 5.Singapore
- 6.Australia
- 8.Canada
- 9.Netherlands
- 10.Finland

## 6 . Classement des pays par potentiel d'implémentation via un scoring :

**mais quels pays choisir parmi ces listes de pays ??**

## 6 . Classement des pays par potentiel d'implémentation via un scoring :

**Attribution des poids pour chaque pays parmi les top 10 relatifs à chaque indicateurs**

|                       | Australia | Bangladesh | Brazil | Canada | China | Denmark | Ethiopia | Finland | Germany | Hong Kong SAR, China | India | Indonesia | Japan | Netherlands |
|-----------------------|-----------|------------|--------|--------|-------|---------|----------|---------|---------|----------------------|-------|-----------|-------|-------------|
| poids_pib             | 0.0       | 0.0        | 0.0    | 0.0    | 0.0   | 5.0     | 0.0      | 0.0     | 0.0     | 1.0                  | 0.0   | 0.0       | 10.0  | 2.0         |
| poids_population15_24 | 0.0       | 3.0        | 4.0    | 0.0    | 9.0   | 0.0     | 1.0      | 0.0     | 0.0     | 0.0                  | 10.0  | 7.0       | 0.0   | 0.0         |
| poids_population      | 0.0       | 3.0        | 6.0    | 0.0    | 10.0  | 0.0     | 0.0      | 0.0     | 0.0     | 0.0                  | 9.0   | 7.0       | 1.0   | 0.0         |
| poids_Internet        | 0.0       | 0.0        | 0.0    | 2.0    | 0.0   | 9.0     | 0.0      | 5.0     | 1.0     | 0.0                  | 0.0   | 0.0       | 4.0   | 7.0         |
| poids_computer        | 4.0       | 0.0        | 0.0    | 3.0    | 0.0   | 7.0     | 0.0      | 1.0     | 0.0     | 0.0                  | 0.0   | 0.0       | 0.0   | 2.0         |

Activer Wi

## 6 . Classement des pays par potentiel d'implémentation via un scoring :

Pour les 5 indicateurs réaliser des itérations et à chaque itération on attribue des poids allant de 1 à 5 qui se diffère d'une itérations à une autre.

```
poids_indicateur= []
for i in list(itertools.permutations([1, 2, 3,4,5])):
    array_i= np.array(i)
    poids_indicateur.append(array_i)
```

Entrée [112]: poids\_indicateur


Out[112]: [array([1, 2, 3, 4, 5]),  
array([1, 2, 3, 5, 4]),  
array([1, 2, 4, 3, 5]),  
array([1, 2, 4, 5, 3]),  
array([1, 2, 5, 3, 4]),  
array([1, 2, 5, 4, 3]),  
array([1, 3, 2, 4, 5]),  
array([1, 3, 2, 5, 4]),  
array([1, 3, 4, 2, 5]),  
array([1, 3, 4, 5, 2]),  
array([1, 3, 5, 2, 4]),  
array([1, 3, 5, 4, 2]),  
array([1, 4, 2, 3, 5]),  
array([1, 4, 2, 5, 3]),  
array([1, 4, 3, 2, 5]),  
array([1, 4, 3, 5, 2]),  
array([1, 4, 5, 2, 3]),  
array([1, 4, 5, 3, 2]),  
array([1, 5, 2, 3, 4]),  
array([1, 5, 2, 4, 3])]

## 6 . Classement des pays par potentiel d'implémentation via un scoring :

**Chaque ligne de la matrice représente le produit matriciel de l'itération i du vecteur poids indicateur multiplié par la matrice poids pays**

| Australia | Bangladesh | Brazil | Canada | China | Denmark | Ethiopia | Finland | Germany | Hong Kong SAR, China | India | Indonesia | Japan | Netherlands | Nigeria | Norway | Pakistan | Russian Federation | S |
|-----------|------------|--------|--------|-------|---------|----------|---------|---------|----------------------|-------|-----------|-------|-------------|---------|--------|----------|--------------------|---|
| 20.0      | 15.0       | 26.0   | 23.0   | 48.0  | 76.0    | 2.0      | 25.0    | 4.0     | 1.0                  | 47.0  | 35.0      | 29.0  | 40.0        | 22.0    | 74.0   | 27.0     | 10.0               |   |
| 16.0      | 15.0       | 26.0   | 22.0   | 48.0  | 78.0    | 2.0      | 29.0    | 5.0     | 1.0                  | 47.0  | 35.0      | 33.0  | 45.0        | 22.0    | 79.0   | 27.0     | 10.0               |   |
| 20.0      | 18.0       | 32.0   | 21.0   | 58.0  | 67.0    | 2.0      | 20.0    | 3.0     | 1.0                  | 56.0  | 42.0      | 26.0  | 33.0        | 26.0    | 64.0   | 32.0     | 12.0               |   |
| 12.0      | 18.0       | 32.0   | 19.0   | 58.0  | 71.0    | 2.0      | 28.0    | 5.0     | 1.0                  | 56.0  | 42.0      | 34.0  | 43.0        | 26.0    | 74.0   | 32.0     | 12.0               |   |
| 16.0      | 21.0       | 38.0   | 18.0   | 68.0  | 60.0    | 2.0      | 19.0    | 3.0     | 1.0                  | 65.0  | 49.0      | 27.0  | 31.0        | 30.0    | 59.0   | 37.0     | 14.0               |   |
| 12.0      | 21.0       | 38.0   | 17.0   | 68.0  | 62.0    | 2.0      | 23.0    | 4.0     | 1.0                  | 65.0  | 49.0      | 31.0  | 36.0        | 30.0    | 64.0   | 37.0     | 14.0               |   |
| 20.0      | 15.0       | 24.0   | 23.0   | 47.0  | 76.0    | 3.0      | 25.0    | 4.0     | 1.0                  | 48.0  | 35.0      | 28.0  | 40.0        | 23.0    | 74.0   | 28.0     | 10.0               |   |
| 16.0      | 15.0       | 24.0   | 22.0   | 47.0  | 78.0    | 3.0      | 29.0    | 5.0     | 1.0                  | 48.0  | 35.0      | 32.0  | 45.0        | 23.0    | 79.0   | 28.0     | 10.0               |   |
| 20.0      | 21.0       | 36.0   | 19.0   | 67.0  | 58.0    | 3.0      | 15.0    | 2.0     | 1.0                  | 66.0  | 49.0      | 22.0  | 26.0        | 31.0    | 54.0   | 38.0     | 14.0               |   |


## 6 . Classement des pays par potentiel d'implémentation via un scoring :



## 6 . Classement des pays par potentiel d'implémentation via un scoring :



## 6 . Classement des pays par potentiel d'implémentation via un scoring :



## 7 . Evaluation du potentiel des pays choisis :

```
pib_change = dataN.groupby('Country Name')['GDP'].apply(lambda x: x.pct_change().mean()).reset_index(name='taux_croissance_pib')
pib_change['categorie_pib'] = np.where(pib_change['taux_croissance_pib'] < 0, 'decreasing', np.where(pib_change['taux_croissance_pib'] > 0, 'increasing', 'stable'))

population_change = dataN.groupby('Country Name')['Population'].apply(lambda x: x.pct_change().mean()).reset_index(name='taux_croissance_population')
population_change['categorie_population'] = np.where(population_change['taux_croissance_population'] < 0, 'decreasing', np.where(population_change['taux_croissance_population'] > 0, 'increasing', 'stable'))

population15_24_change = dataN.groupby('Country Name')['Population 15-24'].apply(lambda x: x.pct_change().mean()).reset_index(name='taux_croissance_population15_24')
population15_24_change['categorie_population15_24'] = np.where(population15_24_change['taux_croissance_population15_24'] < 0, 'decreasing', np.where(population15_24_change['taux_croissance_population15_24'] > 0, 'increasing', 'stable'))





Internet_users_change = dataN.groupby('Country Name')['Internet users'].apply(lambda x: x.pct_change().mean()).reset_index(name='taux_croissance_Internet')
Internet_users_change['categorie_Internet'] = np.where(Internet_users_change['taux_croissance_Internet'] < 0, 'decreasing', np.where(Internet_users_change['taux_croissance_Internet'] > 0, 'increasing', 'stable'))

Computers_change = dataN.groupby('Country Name')['Personal computers'].apply(lambda x: x.pct_change().mean()).reset_index(name='taux_croissance_Computers')
Computers_change['categorie_computers'] = np.where(Computers_change['taux_croissance_Computers'] < 0, 'decreasing', np.where(Computers_change['taux_croissance_Computers'] > 0, 'increasing', 'stable'))

from functools import reduce
dfs= [pib_change, population_change, population15_24_change, Internet_users_change, Computers_change]
df_final = reduce(lambda left,right: pd.merge(left,right,on='Country Name'), dfs)
df_final= df_final.set_index('Country Name')
df_final
```

# 7 . Evaluation du potentiel des pays choisis :

Taux de croissance des différents indicateurs



## 7 . Evaluation du potentiel des pays choisis :

| Country Name  | categorie_pib | categorie_population | categorie_population15_24 | categorie_Internet | Nbr_Increasing |
|---------------|---------------|----------------------|---------------------------|--------------------|----------------|
| China         | increasing    | increasing           | decreasing                | increasing         | 3              |
| Denmark       | decreasing    | increasing           | increasing                | increasing         | 3              |
| India         | increasing    | increasing           | increasing                | increasing         | 4              |
| Indonesia     | increasing    | increasing           | decreasing                | increasing         | 3              |
| Japan         | decreasing    | decreasing           | decreasing                | increasing         | 1              |
| Netherlands   | decreasing    | increasing           | increasing                | increasing         | 3              |
| Norway        | decreasing    | increasing           | increasing                | increasing         | 3              |
| Sweden        | decreasing    | increasing           | decreasing                | increasing         | 2              |
| Switzerland   | increasing    | increasing           | increasing                | increasing         | 4              |
| United States | increasing    | increasing           | increasing                | increasing         | 4              |

# Conclusion :

- ❖ Qualité de ce jeu de données

Le jeu contient beaucoup de données non renseignées

- ❖ Description des informations

5 Jeu de données : Country , data , indicateurs , description et source

- ❖ Informations pertinentes à la problématique

Des indicateurs pertinents ont été sélectionnés

- ❖ Ordres de grandeurs de quelques indicateurs pertinents

Des informations intéressantes ont pu être mises en évidences